Trabalho de Conclusão de Curso

PÓS-GRADUAÇÃO EM CIÊNCIA DE DADOS E INTELIGÊNCIA ARTIFICIAL

ALUNO: Marcus Vinícius Longon Sobral
ORIENTADOR: Marcelo Cohen

PUCRS online uol edtech

Sumário

1. RESUMO 2
2. INTRODUÇÃO 3
3. TRABALHOS RELACIONAIS 4
4. METODOLOGIA 4
5. RESULTADOS 10
6. DISCUSSÃO 13
7. CONCLUSÃO E TRABALHOS FUTUROS 14
8. REFERÊNCIAS 15

Classificação da informação: Uso Interno

PUCRS online

1. RESUMO

Os métodos de Machine Learning aplicados neste trabalho foram implementados com vistas a melhor entender e trazer novas abordagens para a análise e decisão da concessão de crédito para uma instituição financeira cooperativa. As condições econômicas atuais demonstram um grande aumento no endividamento das famílias e de inadimplência no sistema financeiro nacional, o que prejudica o resultado gerado pela carteira de crédito. Nesse contexto, a análise precisa evoluir de acordo com o apetite a risco das instituições, com vistas à redução da inadimplência e das provisões de crédito de liquidação duvidosa (provisões de risco de crédito em função da qualidade das operações que compõe a carteira). O modelo utilizado para as predições de classificação de possíveis inadimplências foi o *XGBoost*, que utiliza uma abordagem similar ao modelo de *Random Forests*, trazendo ganhos com processamentos paralelos e regularização. Apesar de desvantagens em sua interpretabilidade mais complexa e maior demanda de processamento, a avaliação do modelo comprova sua eficácia e aplicabilidade em tarefas do mundo real. A tendência é que com novos dados e mais estudo sobre novas features o modelo se torne cada vez mais preciso.

2. INTRODUÇÃO

Instituições financeiras têm cada vez mais desafios na concessão de crédito a seus clientes em níveis de risco aceitáveis e mensuráveis. O objetivo aqui proposto é o de avaliar as principais variáveis disponíveis no momento da concessão de crédito para a Cooperativa Sicredi Alta Noroeste SP. Adicionalmente, a proposta é a de aprovação automática de operações com base na melhor avaliação de features como forma de agilizar a disponibilização dos créditos aos tomadores, com a finalidade de redução de risco.

O desafio proposto se ampara na análise de operações vigentes, as quais foram aprovadas por meios automáticos (parâmetros vigentes e históricos decididos pelas mais diversas formas de análise) e por meio de comitês formados por dirigentes e gestores (decisões humanas).

O indicador alvo é aquele que melhor reflete a existência de default (inadimplência). Para isso, a base trará dados sobre a operação apresentar inadimplência, o que refletirá se a operação se encontra dentro da classficação desejada.

3. TRABALHOS RELACIONAIS

Em pesquisa a trabalhos recentes foi notado que as abordagens utilizadas por alguns autores contribuem positivamente na implementação de uma abordagem adequada e testada.

Segundo Coelho (1996), foram avaliados, principalmente, os métodos de Regressão Logística, *Random Forests* e *XGBoost*, onde ficou evidenciada a maior eficácia do *XGBoost* na previsão de inadimplência de tomadores de crédito. Outro ponto observado pelo autor é que o modelo é potencializado com a utilização de dados não financeiros.

Fabio Ceruti (2023), trouxe uma metodologia baseada em alguns modelos de Machine Learning dos quais a Regressão Logística se destacou com o uso do *GridSearchCV* (ferramenta do *Scikit Learn* para identificação dos melhores hiperparâmetros para *tuning* do modelo).

Quando comparado com outros modelos Raffaela Loffredo (2021) também obteve bons resultados com o *XGBoost* e citou que sua utilização é benéfica pela possibilidade de *fine tuning* diante da variedade de hiper parâmetros, o que pode tornar sua aplicação mais precisa.

Loffredo e Ceruti utilizaram bases cedidas pela Nubank, já Coelho utilizou uma base cedida pela Serasa Experian. Logo, os modelos testados não são comparáveis entre si, mas demonstram a aplicação e validação utilizada em cada caso, onde é possível evidenciar suas performances através da utilização da Curva ROC e Matriz de Confusão.

4. METODOLOGIA

A base analisada será disponibilizada com anonimização de dados visto legislação vigente (Lei 13.709/2018, Lei Geral de Proteção de Dados Pessoais - LGPD). Porém, os dados mascarados serão únicos para possibilitar a

identificação única de correntistas e de operações de crédito.

A linguagem escolhida para programação foi o Python. Para a obtenção dos dados foram considerados 6 datasets internos:

- base_rel: Dados de identificação anonimizados, tipo de pessoa – PF ou PJ, associado desde – para cálculo do tempo de associação, idade, renda e faturamento (em duas colunas transformadas em coluna única);
- portfolio: Dados de identificação anonimizados, dados de código das operações anonimizados, classificação de risco interno, tipo de operação, valor financiado da operação, saldos inadimplentes por faixa de atraso *("over 30", "over 60" e "over 90");*
    - A partir desse *data frame* foi criado outro *data frame* para apurar o comprometimento total de cada indivíduo (ou seja, o valor total de operações);
- garantias: Dados de código das operações anonimizados, tipo de garantia vinculada;
- scr: Dados de identificação anonimizados, valor devidos por faixa de data a vencer (a partir desses dados foi consolidado em coluna única representando valor total devido no Sistema Financeiro Nacional a vencer em até 360 dias);
- severidade: Dados de identificação anonimizados, apontamentos de restritivos (internos e externos);
- conglomerado: Dados de identificação anonimizados, código de conglomerados (grupos econômicos).

A primeira etapa realizada foi a importação dos arquivos parquet para início da apuração. No processo de pré-processamento foram utilizadas as bibliotecas *NumPy* (para operações numéricas), *Pandas* (para manuseio de data frames) e *datetime* (para transformação de séries históricas).

Visto que as bases encontram-se em bancos de dados e visando velocidade no processamento, os datasets foram utilizados em formato parquet. Inicialmente os dados foram ajustados para os formatos adequados:

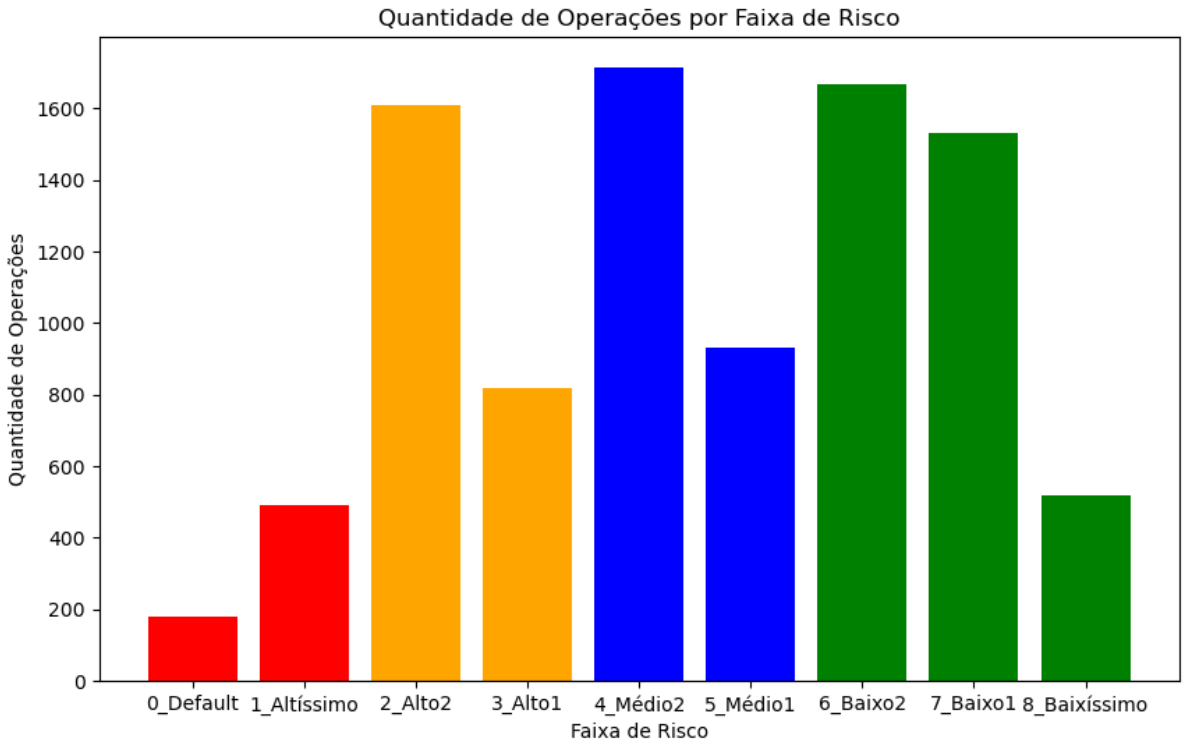
- Os formatos de renda anuais foram calculados para mensais (valores nulos obtidos foram convertidos para zero):

- Dados categóricos foram convertidos para numéricos (com a finalidade de estarem adequados ao processamento do *XGBoost*);
- A base de endividamento no Sistema Financeiro Nacional (SCR) foi adaptada para refletir o endividamento anual de cada indivíduo;
- Foi filtrado apenas os dados de Pessoas Físicas.

Feito isso, foi criada a base única obtida a partir do merge de todas as bases, considerando que o portfolio é o cerne, por representar a relação total de operações.

Foram obtidos o total de 9.458 operações de crédito, das quais 68% concentram-se em tomadores de Médio e Baixo risco.

Gráfico 1 – Quantidade de Operações por Faixa de Risco



Fonte: Elaboração do autor

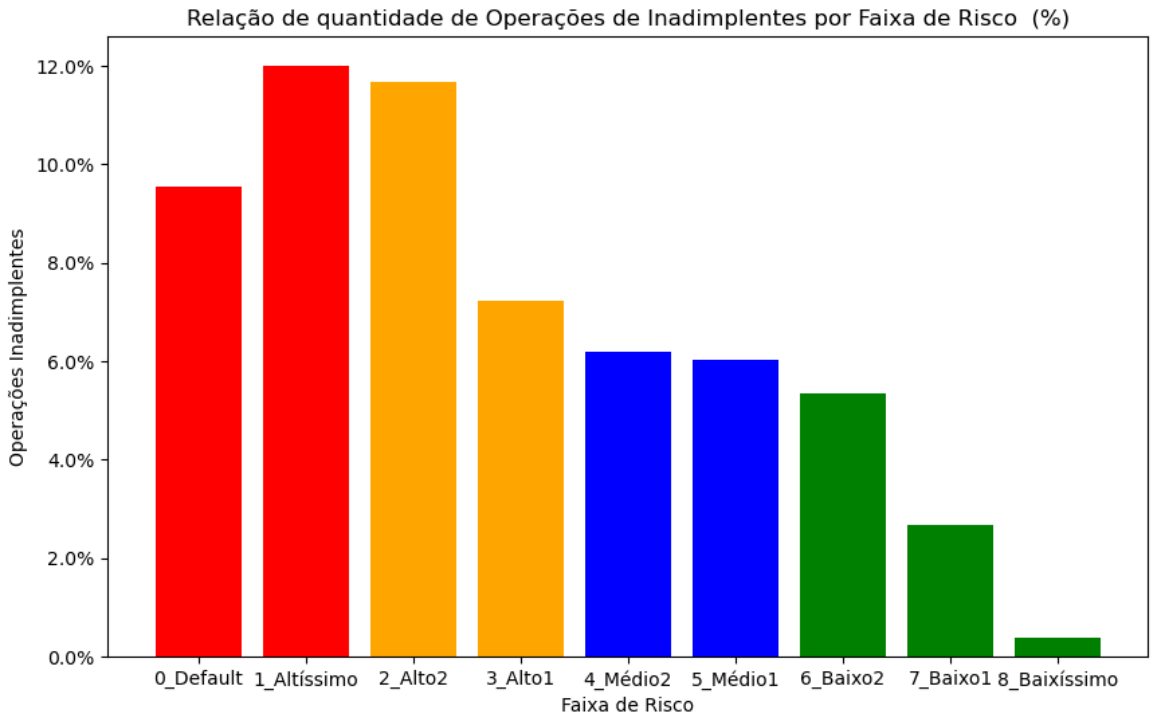
Figura 1 – Quantidade de Operações por Faixa de Risco

	Faixa de Risco	Quantidade
8	0_Default	178
7	1_Altíssimo	492
2	2_Alto2	1610
5	3_Alto1	817
0	4_Médio2	1714
4	5_Médio1	930
1	6_Baixo2	1667
3	7_Baixo1	1533
6	8_Baixíssimo	517

Fonte: Elaboração do autor

Foi avaliado, também, a qualidade das operações de forma relativa. Inicialmente, sob olhar de quantidade é possível notar maior concentração de operações tomadas por pessoas com riscos alto ou pior.

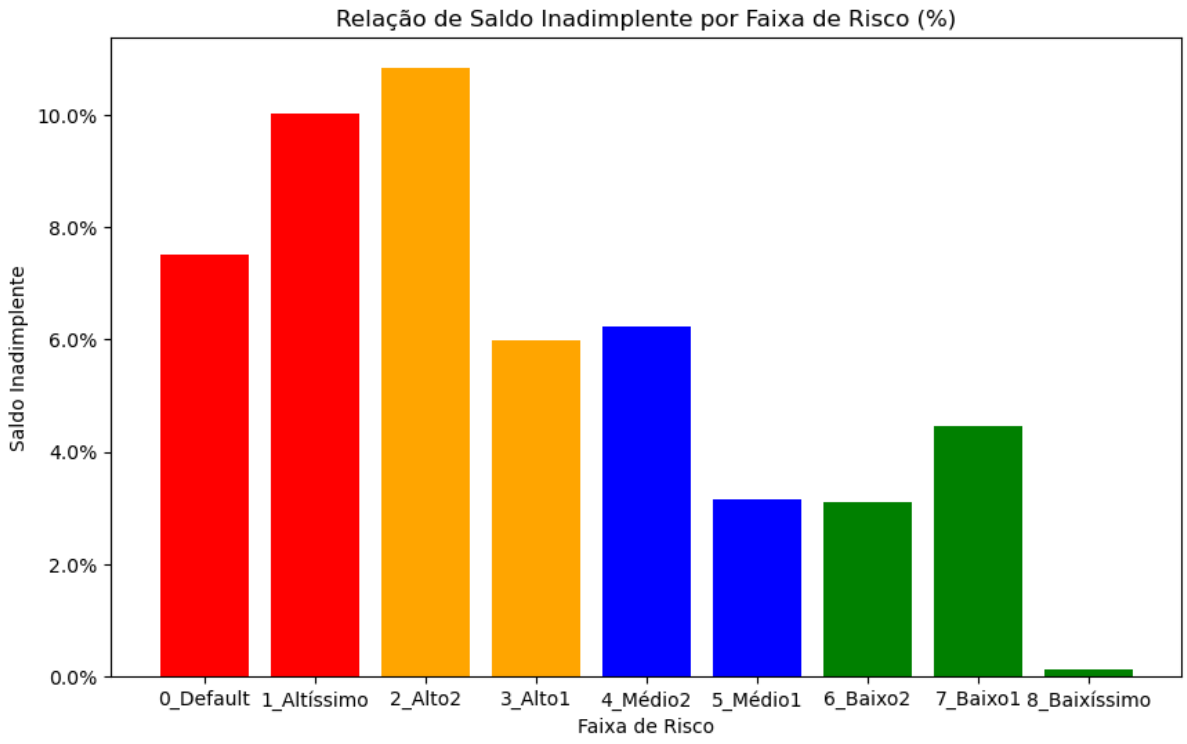
Gráfico 1 – Relação de quantidade de Operações de Inadimplentes por Faixa de Risco (%)



Fonte: Elaboração do autor

Analisando a mesma relação, mas agora em visão de saldo tomado, vemos que a relação de riscos alto ou pior se mantém, mas agora notamos que o saldo de operações de tomadores em faixa de risco Médio 2 se torna mais relevante.

Gráfico 3 – Relação de Saldo Inadimplentes por Faixa de Risco (%)



Fonte: Elaboração do autor

Tendo em vista a maior concentração de operações inadimplentes nas faixas de risco Médio 2 ou pior, foi realizado um filtro na base para considerar apenas operações cujos tomadores estejam nessas faixas. Com o filtro aplicado, a quantidade de dados reduziu para 4.811 operações, das quais 8,92% estão com inadimplência superior a 30 dias (conforme figura 2).

Esse filtro torna a análise mais direcionada em dados com maior probabilidade de inadimplência, e torna o modelo mais aplicável na prática.

Figura 2 – Dados dos contratos filtrados

```
Quantidade de Contratos: 4811
Contratos adimplentes: 4382
Contratos inadimplentes: 429
Contratos inadimplentes (%): 8.917%
```

Fonte: Elaboração do autor

Para a construção do modelo foram utilizadas as bibliotecas:

- *xgboost*: para criação do modelo *XGBoost*
- *sklearn.model_selection*: do qual foram utilizados:
    - *train_test_split*: para segmentação da base original em uma de treino (cerca de 75% dos dados), e outra de teste (cerca de 25% dos dados), e;
    - *GridSearchCV*: para otimização dos hiperparâmetros do classificador e identificação dos melhores parâmetros;
- *sklearn.metrics*: do qual foram utilizados:
    - *accuracy_score*
    - *precision_score*
    - *recall_score*
    - *f1_score*
    - *roc_auc_score*
    - *roc_curve*
    - *confusion_matrix*
    - *ConfusionMatrixDisplay*
    - *classification_report*
- *matplotlib.pyplot*: para criação de visualizações (finalidade de apoiar nas avaliações)
- *numpy*: para operações numéricas.

Após determinar o objetivo alvo sendo os dados de "*over 30*", foi realizada a separação da base para treino e para teste, seguindo a boa prática de proporção aproximada a 75%/25%.

Para criação do modelo, foi definido o objetivo "*binary: logistic*" (usado para regressão logística binária, atendendo à classificação da feature alvo definida). A partir da criação do modelo, foi utilizado o *GridSearchCV*, com a finalidade de identificar os melhores parâmetros, conforme os scores de Curva ROC, que após um processo de *tuning* os melhores hiperparâmetros obtidos foram *{'colsample_bytree': 0.9, 'learning_rate': 0.5, 'max_depth': 6, 'n_estimators': 250, 'subsample': 1.0}*.

Com o modelo treinado e testado, foi iniciado o processo de avaliação do modelo através das métricas, descritas abaixo (de acordo com Tomida & Cruz,

2022):

- Acurácia: “A acurácia mensura a proporção do número de classes previstas corretamente em relação a totalidade das classes”;
- Precisão: “A precisão é uma métrica que indica, dentre as classificações positivas do modelo, quantas foram corretamente previstas”;
- Recall: “Já a revocação é uma métrica que indica, dentre as amostras positivas existentes, quantas o modelo previu corretamente”;
- F1-Score: ”(...) calcula a média harmônica entre precisão e revocação”.

Ainda utilizamos a:

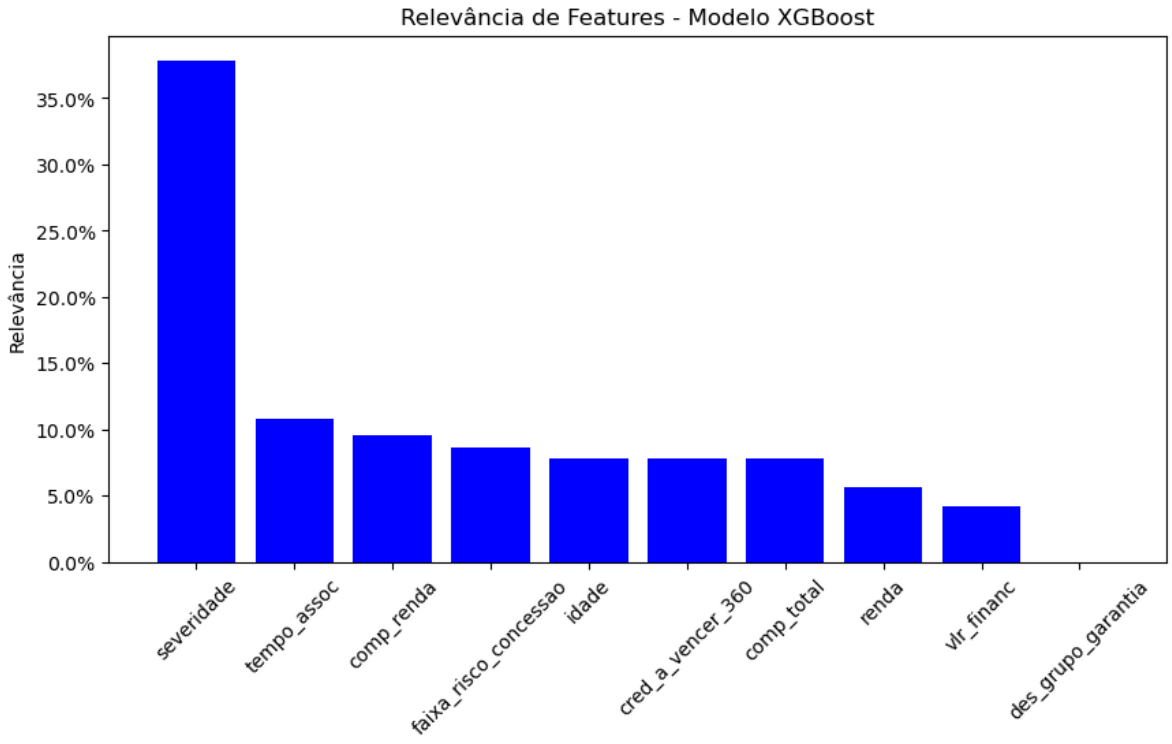
- Curva ROC: A qual de acordo com Mario Filho (2023) representa a “fração de positivos verdadeiros no eixo Y e a fração de falsos positivos no eixo X para diferentes pontos de corte da previsão”;
- Matriz de Confusão: para demonstrar quantas predições foram realizadas corretamente ou erroneamente, sendo:
  - Verdadeiro Positivo: Predição positiva para rótulo positivo;
  - Falso Positivo: Predição positiva para rótulo negativo;
  - Verdadeiro Negativo: Predição negativa para rótulo negativo;
  - Falso Negativo: Predição negativa para rótulo negativo.

5. RESULTADOS

Como exposto acima, o modelo escolhido para avaliação da base foi o *XGBoost* (*Extreme Gradient Boosting*). De forma resumida, ele realiza o *ensemble* de diversas árvores de decisão. Segundo Marinho (2021): *“o gradient boosting é uma técnica de aprendizagem de máquina utilizada para problemas de regressão e classificação, na qual produzem um modelo de predição na forma de árvores de decisão”*. Os grandes ganhos estão na grande diversidade de possibilidades de *tuning* dos hiperparâmetros, além de processamentos paralelos e regularização (para redução de custo, consequentemente, reduzindo *overfitting*).

Processado e criado o modelo, nota-se que as features mais relevantes foram ‘severidade’, ‘tempo_assoc’ e ‘comp_renda’, logo, espera-se que o impacto dessas variáveis ao modelo será mais relevante.

Gráfico 4 – Relevância de Features – Modelo XGBoost



Fonte: Elaboração do autor

A avaliação do modelo revelou indicadores da qualidade do modelo aplicado aos dados de teste. Com 95% de acurácia, é demonstrado que o modelo conseguiu identificar boa parte de todos os rótulos reais da base oficial.

Agregado a isso a precisão retornou um valor de 78%, ou seja, moderada eficácia na previsão de dados positivos (verdadeiros e falsos positivos).

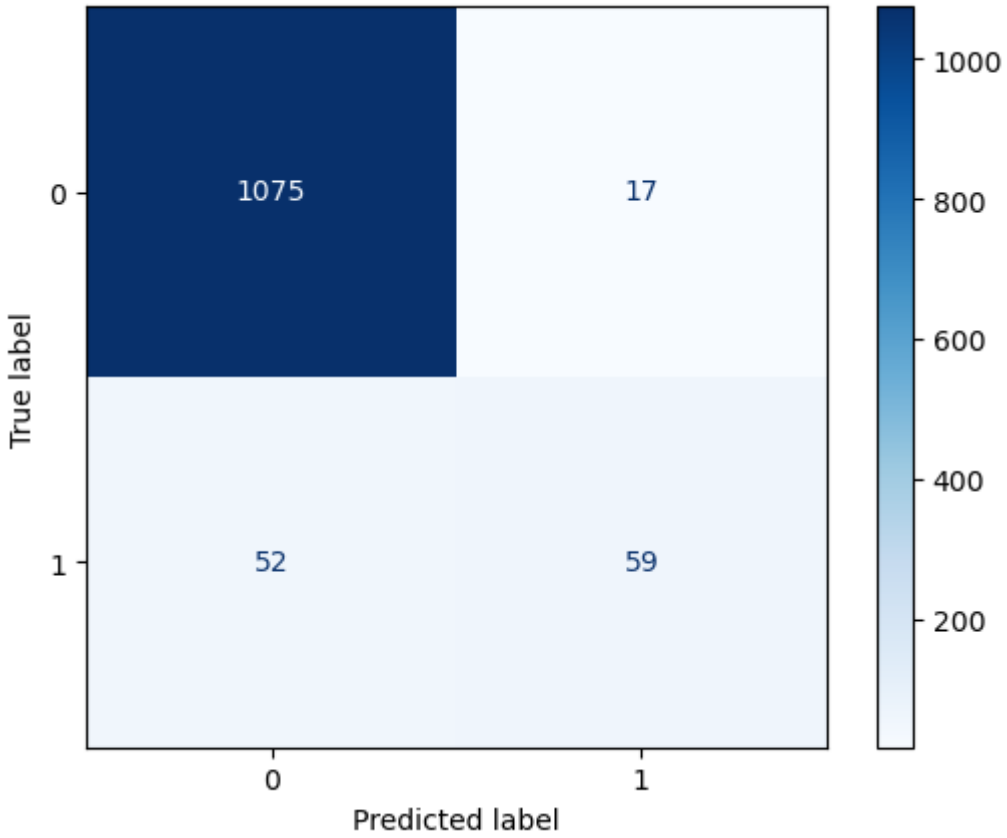
Gráfico 4 – Relação de indicadores de avaliação do modelo

	precision	recall	f1-score	support
0	0.95	0.98	0.97	1092
1	0.78	0.53	0.63	111
accuracy			0.94	1203
macro avg	0.87	0.76	0.80	1203
weighted avg	0.94	0.94	0.94	1203

Fonte: Elaboração do autor

Com a finalidade de avaliar os dados que foram classificados corretamente, optou-se pela Matriz de Confusão. A sua eficácia na visualização da classificação se dá por expor claramente a quantidade de dados classificado como positivos ou negativos em relação aos rótulos reais. O que comprova tanto a acurácia, quanto a precisão.

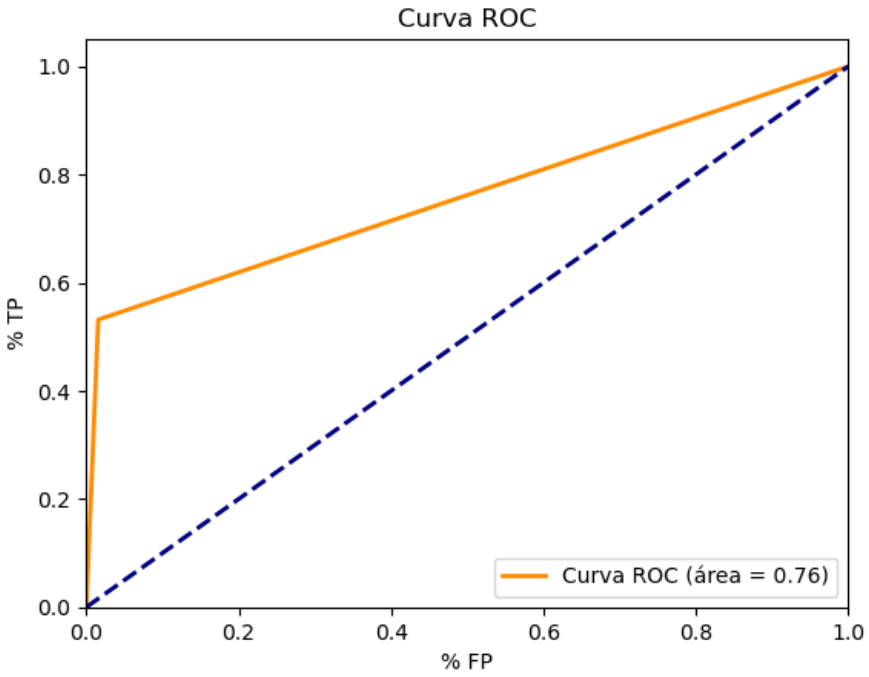
Gráfico 5 – Matriz de confusão



Fonte: Elaboração do autor

Por fim, foi agregada análise da Curva ROC com a finalidade de avaliar o comportamento da ocorrência de dados positivos (verdadeiros e falsos) ao passo que são feitos cortes no processamento do modelo. A linha tracejada azul representa o limiar de 50% da área, representando que modelos que resulte em valores abaixo de 50% não possuem eficácia preditiva. O modelo aqui obtido resultou 76%, garantindo maior qualidade preditiva.

Gráfico 6 – Curva ROC



Fonte: Elaboração do autor

6. DISCUSSÃO

A avaliação dos dados trouxe luz para uma visão mais clara da base estudada e eliminou alguns vieses naturais que surgem ao observar features como a '*faixa_risco_concessão*' (que por natureza reflete o risco que cada tomador representa para a instituição, conforme seus modelos internos de classificação de risco) o qual pode por muitas vezes ser interpretada com a principal variável para resultar em inadimplência, porém, ao analisar sua relevância no modelo nota-se que é uma das menos impactantes. Já outras variáveis que podem passar despercebidas são muito mais relevantes, a exemplo de 'tempo_assoc' (que representa o tempo de associação do tomador junto a instituição cooperativa).

O *tuning* do modelo apoiado pelo GridSearchDV trouxe ganhos relevantes, principalmente, pela sua capacidade de identificar os melhores hiperparâmetros (conforme o objetivo designado), assim, é visto que o mesmo se torna um grande aliado no momento de testar suposições, bem como,

aprender quais hiperparâmetros podem impactar na melhora dos indicadores de avaliação desejados (no caso do trabalho aqui executado, a busca foi pela melhoria da precisão e da Curva ROC). A fim de registro, no momento da primeira parametrização dos hiperparâmetros, a Curva ROC obtida foi de 66%, e no teste final atingiu-se os 76% aqui expostos.

O objetivo principal era o de atingir um modelo capaz de prever inadimplência acima de 30 dias, porém, como os dados disponíveis traziam apenas 8,92% dos dados inadimplentes (uma pequena fração), a preocupação inicial era se o modelo seria capaz de predizer corretamente os rótulos. E, apesar disso, pudemos constatar que o modelo resultou em uma precisão de 78% dos dados de teste.

7. CONCLUSÃO E TRABALHOS FUTUROS

Em termos gerais, constata-se que a avaliação do modelo gerado foi satisfatória. Por outro lado, alguns pontos poderiam ser melhorados/ incrementados, como: a seleção de features adicionais (visando testar e comparar com as features atuais e proporcionar ganhos ao modelo), a utilização de mais hiperparâmetros (busca de refinar a Curva ROC e atingir maior qualidade de predição), outras formas de interpretabilidade do modelo (trazer formas mais visuais que reforcem a forma de classificação para apresentação a usuários menos familiarizados a modelos de Machine Learning).

Ainda, pode-se atribuir um fator de sucesso sobre a análise, no que se refere aos dados utilizados, a qualidade dos mesmos garantiu maior confiabilidade e redução de viés.

Em resumo, o modelo atendeu ao objetivo proposto, demonstrando sua capacidade preditiva e precisão, além de demonstrar escalabilidade para outras linhas de crédito e público-alvo, garantindo menores taxas de inadimplência e acelerando a análise de decisão de crédito.

O código desenvolvido para as contatações em questões pode ser acessado via GitHub, através do link: https://github.com/marclongon/pucrs_artigo_mba.git .

8. REFERÊNCIAS

BANERJEE, Prashant. A Guide on XGBoost hyperparameters tuning. Kaggle, 15 de jul. de 2020. Disponível em> <https://www.kaggle.com/code/prashant111/a-guide-on-xgboost-hyperparameters-tuning>. Acesso em: 16 de jul. de 2024.

CERUTI, Fabio. Construção de modelo preditivo de análise de risco de crédito usando XGBoost. Medium, 07 de nov. de 2023. Disponível em: <https://medium.com/@loffredo.ds/constru%C3%A7%C3%A3o-de-modelo-preditivo-de-an%C3%A1lise-de-risco-de-cr%C3%A9dito-usando-xgboost-0c8be75ae9f0>. Acesso em: 24 de jun. de 2024.

COELHO, Felipe; AMORIM, Daniel; CAMARGOS, Marcos. Analisando métodos de machine learning e avaliação do risco de crédito. Revista Gestão & Tecnologia, Elsevier: 1996, v. 29, n. 9, p. 1223–1230.

FILHO, Mario. Guia Completo Sobre ROC AUC Em Machine Learning. Mario Filho, 04 de jan. de 2023. Disponível em: <https://mariofilho.com/guia-completo-sobre-roc-auc-em-machine-learning/#:~:text=ROC%20AUC%20%C3%A9%20uma%20m%C3%A9trica,Caracter%C3%ADstica%20de%20Opera%C3%A7%C3%A3o%20do%20Receptor>. Acesso em: 15 de jul. de 2024.

LOFFREDO, Raffaela. Avaliação de Risco de Crédito com Machine Learning. Medium, 29 de jun. de 2021. Disponível em: <https://medium.com/data-hackers/avalia%C3%A7%C3%A3o-de-risco-de-cr%C3%A9dito-com-machine-learning-3b1dc4d29d5f>. Acesso em: 24 de jun. de 2024.

MARINHO, Tiago. Otimização de hiperparâmetros do XGBoost utilizando meta-aprendizagem. Dissertação de Mestrado - Universidade Federal de Alagoas, Maceió, 2021.

TOMIDA, Mauricio; CRUZ, Maykon. Machine learning para rating de crédito de companhias brasileiras não financeiras. Escola Politécnica da Universidade de São Paulo, São Paulo, 2022.